

МЕТОДИКА ОБНАРУЖЕНИЯ КОМПЬЮТЕРНЫХ АТАК С ПОМОЩЬЮ ФРАКТАЛЬНОГО АНАЛИЗА И МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ

А.М. Крибель, Р.А. Перов, О.С. Лаута, В.Б. Сычужников

В статье рассмотрена методика выявления компьютерных атак для стационарного и нестационарного трафика. Проведен анализ алгоритмов машинного обучения для выявления аномалий, вызванных компьютерными атаками. Также вычислено минимальное количество пакетов для определения точности данной методики.

Ключевые слова: Аномалии, компьютерные атаки, сеть передачи данных, метод машинного обучения, стационарный временной ряд, самоподобие.

С каждым годом увеличивается число компьютерных атак, направленных на крупные частные компании, государственные организации и критически важные информационные объекты, что может привести к выводу из строя злоумышленниками систем, поддерживающих жизнеобеспечение человечества и возникновению глобальных техногенных катастроф.

Компьютерные атаки представляют собой сложное комплексное воздействие на сеть, в результате которого осуществляется их компрометация киберресурсов и нарушается управление процессами в сети передачи данных. Зачастую этому предшествует долгая и кропотливая работа: компьютерная техническая разведка, поиск характерных уязвимостей и захват информационных активов. Воздействие компьютерных атак возможно за счет использования технологий сбора информации, малоэффективных механизмов защиты, эксплуатации устаревших сетевых служб, протоколов и операционных систем.

Основная часть. С целью обнаружения аномалий в сетевом трафике в условиях компьютерных атак (КА) разработана методика (рис. 1), позволяющий обнаруживать компьютерные атаки, прогнозировать и обнаруживать компьютерные атаки с минимальным количеством ложных срабатываний благодаря применению методов фрактального анализа для нестационарного и методов машинного обучения для стационарного сетевых трафиков [1].

Методика включает в себя следующие этапы:

сбор сетевого трафика;

проверка на стационарность;

подготовка исходных данных;

фрактальный анализ для нестационарного сетевого трафика;

машинное обучение для стационарного сетевого трафика.

Обнаружение аномалий в нестационарном трафике с помощью фрактального анализа. Для выявления аномалий в нестационарном трафике, применяется фрактальный анализ, который главным образом базируется на вычислении и оценки показателя Херста.

Для оценки аномальности предложено использовать не полезное содержимое пакетов, а взять за основу предложение Унтерова Д.С. [2] о том, что информации из заголовков пакетов будет достаточно. В качестве такой информации будем использовать количественные значения передаваемых флагов (меток, указывающих на тип пакета). Анализ [3] также показывает, что для выявления аномального поведения в трафике, достаточно анализировать его основные параметры и нет необходимости изучать содержимое каждого пакета. Примерами аномалий, обнаруженных на основе анализа телеметрии трафика, является внезапное увеличение интенсивности трафика от рабочей станции или изменение структуры в сравнении с обычными ежедневными показателями для данной сети устройства.




Рис. 1. Общая структура и взаимосвязь этапов метода

На рис. 2 представлена блок-схема метода обнаружения аномальной активности в нестационарном сетевом трафике сети передачи данных (СПД).




Рис. 2. Блок-схема обнаружения аномалий в нестационарном трафике

Сетевой поток делится на группы и рассчитывается показатель Херста для каждой из групп. Сетевые пакеты помечаются аномальными в том случае, когда нарушается свойство самоподобия в исследуемой группе.

Для проверки эффективности предложенного подхода, сперва он был протестирован на легитимном сетевом трафике (рис. 3).




Рис. 3. Вычисление H методом фрактального анализа легитимного UDP трафика. Разбиение 10000 точек на 20 групп

Синей прямой линией обозначен порог, соответствующий границе белого шума ($Hurst = 0,5$). Точки на втором графике соответствуют номерам групп пакетов (всего 30 точек). Точки на третьем соответствуют scales (всего 12 точек). Количество scales влияет на точность и на длительность работы алгоритма. Чем больше количество scales, тем выше точность, и, наоборот, меньше длительность его работы.

Как видно из рис. 4, мера фрактальности для всех групп пакетов полностью лежит выше отметки 0.5. Это указывает на наличие самоподобных свойств у каждой группы. Кроме того, на третьем графике (логарифмической регрессии) отражен параметр Херста для всего DataFrame, который подтверждает наличие фрактальных свойств и повторяющихся процессов.

Далее проводилось тестирование аномального сетевого трафика, полученного во время проведения DoS атаки и компьютерно-технической разведки. При этом преследовалась цель подбора максимального числа групп разбиения, при котором оцениваемый параметр H будет вычисляться с высокой точностью.




Рис. 4. Вычисление H методом фрактального анализа аномального UDP трафика. Разбиение 10000 точек на 20 групп

Из рис. 4 видно, что свойство самоподобия нарушается, т.к. показатель Херста, на каждом из интервалов, меньше порогового значения 0.5. Это свидетельствует о нарушении фрактальной структуры трафика и наличии в нем аномалий. Следовательно, предлагаемый подход способен обнаруживать аномалии в интервалах (группах), состоящих из 500 сетевых пакетов.

Увеличив количество групп до 30, сокращается временной интервал без потери точности обнаружения аномальной активности в сети (рис. 5).

При анализе 40 групп, каждая из которых состоит из 250 сетевых пакетов, наблюдается проявление свойств самоподобия на некоторых участках (рис. 6).

Такое поведение указывает на ухудшение точности из-за малой выборки сетевых пакетов. Следовательно, такое разбиение является неприемлемым. В качестве оптимального разбиения следует считать предыдущее разбиение, состоящее из 250 сетевых пакетов на интервал. Такое количество пакетов обрабатывается за 0.00125 с, что является существенным достоинством данного подхода.

Обнаружение аномалий в стационарном сетевом трафике с помощью методов машинного обучения. Существует множество способов, которые позволяют определить аномалии [4]. На рис. 7-9 продемонстрирована работа наиболее популярных алгоритмов машинного обучения, протестированных на временных рядах, сгенерированных с помощью модели авторегрессионного интегрированного скользящего среднего.




Рис. 5. Вычисление H методом фрактального анализа аномального UDP трафика. Разбиение 10000 точек на 30 групп




Рис. 6. Вычисление H методом фрактального анализа аномального UDP трафика. Разбиение 10000 точек на 40 групп




Рис. 7. Кумулятивные суммы




Рис. 8. Метод опорных векторов




Рис. 9. Изолированный лес

Как видно из рисунков, алгоритмы отлично справляются с обнаружением аномальных выбросов. В таком случае, аномалия проявляется в виде нестационарности некоторых наблюдаемых временных рядов. Это не только мгновенные скачки амплитуды измерений, но и медленные тренды, практически невидимые за время наблюдений. Однако, при тестировании вышеуказанных алгоритмов на реальном сетевом трафике, оказалось, что не всегда выбросы являются аномальными.

На рис. 10-13 изображены протоколы сетевого трафика. Аномальные пакеты помечены красными точками, а легитимные пакеты – зелеными. Как видно из рисунков многие всплески являются легитимными, а отсутствующие всплески – аномальные.

Поэтому остро стоит вопрос по своевременному обнаружению всплесков трафика в СПД, выделению из них аномальных, а также классификации выявленных аномалий с целью прогнозирования факта воздействия КА и выработке эффективных мероприятий противодействия.




Рис. 10. Отправленные пакеты повторно переданы или отброшены




Рис. 11. Количество подключений к серверу




Рис. 12. Состояние параметров tcp заголовка за время жизни ip пакета




Рис. 13. скорость передачи пакетов bit/сек

Обнаружение аномалий с помощью классификаторов. Чтобы оценить эффективности популярных классификаторов, формируется новый датасет содержащий коррелируемые параметры с аномальными запросами. Для этого строится матрица корреляции.




Рис. 14. Матрица корреляции

Параметр label – индикатор показывающий наличие аномалий. Для удобства выбрано 20 наиболее коррелируемых с аномалиями параметров (рис. 15). Наибольшему воздействию подвергается параметр sttl (рис. 16).

В качестве классификаторов использовались: логистическая регрессия, метод k-ближайших соседей, бэггинг, градиентный бустинг, случайный лес и адаптивный бустинг. Для каждой модели подбирались гиперпараметры влияющие на точность классификации (рис.17).

На рис. 18 представлены наиболее значимые параметры, влияющие на точность классификации и оценка эффективности обнаружения аномалий классификаторами.

Несмотря на высокую точность обнаружения КА, современные классификаторы имеют существенный недостаток - большое количество ложных срабатываний. В этом легко убедиться, построив матрицу ошибок первого и второго рода, по которой определялась не только точность, но и количество ложных срабатываний.




Рис. 15. Самые коррелируемые параметры




Рис. 16. Время жизни пакета от источника к отправителю

```

In [49]: models = []
names = ['LogisticRegression', 'KNeighborsClassifier', 'BaggingClassifier', 'GradientBoostingClassifier', 'RandomForestClassifier', 'AdaBoostClassifier']

models.append(LogisticRegression(max_iter=1000, n_jobs=-1))
models.append(KNeighborsClassifier(n_jobs=-1))
models.append(BaggingClassifier())
models.append(GradientBoostingClassifier())
models.append(RandomForestClassifier())
models.append(AdaBoostClassifier())

In [50]: params = {
models[0]: {'solver': ['sag', 'lbfgs'], 'penalty': ['l1', 'l2']},
models[1]: {'n_neighbors': list(range(1, 31)), 'weights': ['uniform', 'distance']},
models[2]: {'n_estimators': list(range(10, 31))},
models[3]: {'loss': ['deviance', 'exponential'], 'learning_rate': [0.1, 0.03, 0.5], 'max_depth': list(range(3, 30))},
models[4]: {'n_estimators': list(range(10, 30)), 'max_depth': list(range(5, 31))},
models[5]: {'learning_rate': list(np.arange(0.02, 0.1)), 'n_estimators': list(range(50, 100))},
}

In [51]: import warnings
warnings.filterwarnings('ignore')

for name, model in zip(names, models):
    search = GridSearchCV(estimator=model, param_grid=params[model], n_jobs=-1, cv=5)
    search.fit(X_train, y_train)

    print('-----')
    print('Classifier: ' + str(search.best_estimator_))
    print('Best parameters: ' + str(search.best_params_))
    print('Best score: ' + str(search.best_score_))
    print('-----')

```

Рис. 17. Подбор гиперпараметров

```

Classifier: LogisticRegression(max_iter=1000, n_jobs=-1)
Best parameters: {'penalty': 'l2', 'solver': 'lbfgs'}
Best score: 0.8961687849910088

Classifier: KNeighborsClassifier(n_jobs=-1, n_neighbors=1)
Best parameters: {'n_neighbors': 1, 'weights': 'uniform'}
Best score: 0.999323288700103

Classifier: BaggingClassifier(n_estimators=15)
Best parameters: {'n_estimators': 15}
Best score: 0.9995141569933788

Classifier: GradientBoostingClassifier(learning_rate=0.5, max_depth=6)
Best parameters: {'learning_rate': 0.5, 'loss': 'deviance', 'max_depth': 6}
Best score: 0.9999305932110504

Classifier: RandomForestClassifier(max_depth=23, n_estimators=13)
Best parameters: {'max_depth': 23, 'n_estimators': 13}
Best score: 0.9991324294388775

Classifier: AdaBoostClassifier(learning_rate=1.9000000000000001, n_estimators=51)
Best parameters: {'learning_rate': 1.9000000000000001, 'n_estimators': 51}
Best score: 0.9999305932110504

```

Рис. 18. Сравнение точности классификаторов




Рис. 19. Матрица ошибок первого и второго рода логистической регрессии, случайного леса и дерева решений

Полученные результаты подтверждают тот факт, что проблемой современных классификаторов является плохая способность распознавать неизвестные аномалии (атаки нулевого дня). Также, при тестировании вышеуказанных алгоритмов на реальном сетевом трафике оказалось, что не всегда выбросы являются аномальными; происходят ложные срабатывания. Поэтому острым является вопрос классификации компьютерных атак от ложных срабатываний.

Заключение. В статье разработана методика, позволяющая выявлять аномалии в нестационарном сетевом трафике с помощью фрактального анализа. Проведен эксперимент по нахождению рационального числа пакетов, необходимых для своевременного выявления аномалий с помощью фрактального анализа, с целью достижения своевременности и полноты при обнаружении аномалий в нестационарном трафике. Вычислено оптимальное число пакетов необходимых для выявления аномалий в СПД за интервал времени.

Проведен анализ алгоритмов машинного обучения и классификаторов, предназначенных для выявления КА. Выявлены их недостатки, которые главным образом заключаются в большом количестве ложных срабатываний, а также отсутствии возможности работать в режиме реального времени и обнаружения КА «нулевого дня».

Главным достоинством методики является возможность работы в режиме реального времени, а также возможность работы с любыми видами трафика. Выявление факта воздействия КА производится за несколько микросекунд в зависимости от производительности вычислительной техники.

Список литературы

1. Kotenko I., Saenko I., Lauta O., Kribel A. Ensuring the survivability of embedded computer networks based on early detection of cyber attacks by integrating fractal analysis and statistical methods. *Microprocessors and Microsystems* this link is disabled, 2022, 90, 104459.
2. Саенко И.Б., Лаута О.С., Карпов М.А., Крибель А.М. Модель угроз ресурсам ИТКС как ключевому активу критически важного объекта инфраструктуры // *Электросвязь*. 2021. № 1. С. 36-44.
3. Карпов М.А., Коцыняк М.А., Нечепуренко А.П. Модель функционирования информационно-телекоммуникационной сети специального назначения в условиях информационного воздействия // *Актуальные проблемы защиты и безопасности: Труды XXIV Всероссийской научно-практической конференции РАРАН. В 7-ми томах, Санкт-Петербург. М.: Российская академия ракетных и артиллерийских наук, 2021. С. 458-462.*
4. Лепешкин О.М., Карпов М.А., Остроумов О.А., Синюк А.Д. Методологический подход управления обеспечением функциональной безопасности и функциональной устойчивости системы связи критически важных объектов и объектов критической информационной инфраструктуры // *FISP-2021: Фундаментальные проблемы информационной безопасности в условиях цифровой трансформации: Сборник докладов III Всероссийской научной конференции (с приглашением зарубежных ученых), Ставрополь, 30 ноября 2021 года. Ставрополь: Северо-Кавказский федеральный университет, 2021. С. 105-110.*

Крибель Александр Михайлович, адъюнкт, nemo4ka74@gmail.com, Россия, Санкт-Петербург, Военная академия связи им. С.М.Буденного,

Перов Роман Александрович, адъюнкт, roma.perov@list.ru, Россия, Санкт-Петербург, Военная академия связи им. С.М.Буденного,

Лаута Олег Сергеевич, д-р техн. наук, профессор, laos-82@yandex.ru, Россия, Санкт-Петербург, Военная академия связи им. С.М.Буденного,

Сычужников Виктор Борисович, старший научный сотрудник, Sych-SPB19@gmail.com, Россия, Санкт-Петербург, Военная академия связи им. С.М.Буденного

METHODS OF DETECTING COMPUTER ATTACKS USING FRACTAL ANALYSIS AND
MACHINE LEARNING METHODS

M.A. Kribel, R.A. Perov, O.S. Lauta, V.B. Sychuzhnikov

Annotation. The article considers the method of detecting computer attacks for stationary and non-stationary traffic. The analysis of machine learning algorithms to identify anomalies caused by computer attacks is carried out. The minimum number of packets to determine the accuracy of this technique is also calculated.

Key words: Anomalies, computer attacks, data transmission network, machine learning method, stationary time series, self-similarity.

Kribel Alexander Mikhailovich, postgraduate, nemo4ka74@gmail.com, Russia, St. Petersburg, Military Academy of Communications named after S.M.Budyonny,

Perov Roman Aleksandrovich, postgraduate, roma.perov@list.ru, Russia, St. Petersburg, Military Academy of Communications named after S.M.Budyonny,

Lauta Oleg Sergeevich, doctor of technical sciences, professor, laos-82@yandex.ru, Russia, St. Petersburg, Military Academy of Communications named after S.M.Budyonny,

Sychuzhnikov Viktor Borisovich, senior researcher, Sych-SPB19@gmail.com, Russia, St. Petersburg, Military Academy of Communications named after S.M.Budyonny

УДК 004

DOI: 10.24412/2071-6168-2022-5-178-186

**ФАКТОРЫ, ВЛИЯЮЩИЕ НА ВЫБОР ОРГАНИЗАЦИОННО-
ТЕХНОЛОГИЧЕСКИХ РЕШЕНИЙ ПРИ СТРОИТЕЛЬСТВЕ ЗДАНИЙ
ИЗ КРУПНОГАБАРИТНЫХ МОДУЛЕЙ (ЧАСТЬ 2)**

Т.К. Кузьмина, Р.Т. Аветисян, А.Т. Мирзаханова

В настоящей работе исследованы факторы, влияющие на принятие организационно-технологических решений на различных этапах объемно-блочного домостроения. В статье представлен экспертный опрос, на основании которого были проведены статистические расчеты. По результатам проведенного исследования была определена наиболее значимая группа факторов, действие которого может оказать наибольшее влияние на качество и безопасность готовой модульной продукции при принятии организационно-технологических решений.

Ключевые слова: крупногабаритное объемно-блочное домостроение, модульное строительство, качество и безопасность готовой модульной продукции.

Объемно-блочное домостроение является перспективным направлением индустриального метода возведения зданий различного назначения. Индустриальный метод производство крупногабаритных объемных блоков позволяет обеспечить высокую степень заводской готовности модуля, качество выпускаемой продукции, сокращение сроков строительства за счет уменьшения числа операций на строительной площадке [1-5]. Крупногабаритное модульное домостроение – гарант качества и высокой производительности труда [6-10].